

數字政策辦公室

人工智能道德框架

簡易參考指南

第 2.0 版

2025 年 12 月

© 中華人民共和國

香港特別行政區政府

修改記錄				
修改 次數	修改詳情	經修改頁數	版本編號	日期
1	將「政府資訊科技總監辦公室」更改為 「數字政策辦公室」		1.1	2024 年 7 月
2	更新第1-6章	第1-6章	2.0	2025 年 12 月

註：如本文件中英文版本內容存在歧義，請以英文版本為準，並通知數字政策辦公室。

目錄

1.	概覽	2
1.1	引言	2
1.2	何謂人工智能道德框架？	2
1.3	採納人工智能道德框架的重點行動有哪些？	4
2.	人工智能道德原則	5
3.	人工智能治理	8
4.	人工智能生命週期	9
5.	人工智能實務指引	11
6.	人工智能應用影響評估	14

1. 概覽

1.1 引言

本文件旨在讓讀者快速參考並初步了解《人工智能道德框架》(《框架》)及相關程序，以便將道德元素融入機構在資訊科技項目或服務中規劃、設計及實施人工智能和大數據分析應用的過程。

在本文件中，「人工智能」一詞指涉及大數據分析、進階分析及機器學習的運算操作，這些技術透過處理龐大數據集來找出關聯性及作出預測。而「**人工智能應用**」則指一整套由**人工智能模型驅動行動、決策或預測的應用**。人工智能應用的例子，包括具備預測功能和 / 或涉及訓練數據模型開發的資訊科技項目。機構在開展涉及人工智能應用的資訊科技項目時，可參考《框架》的要求。

1.2 何謂人工智能道德框架？

《人工智能道德框架》的最初版本旨在協助政府決策局 / 部門 (局 / 部門) 在規劃、設計及推行資訊科技項目和服務時，妥善應用人工智能及大數據分析技術。該《框架》包含指導原則、最佳實務方案及人工智能評估機制，供局 / 部門在開展人工智能驅動的資訊科技項目時採用。人工智能評估包括供局 / 部門在應用層面使用的評估範本，有助局 / 部門管理相關項目的效益、影響及風險。然而，該《框架》的指導原則、實務指引和評估範本也普遍適用於其他機構，此版本經過適當修改 (例如刪除或修訂只適用於政府的特定用語)，以供機構在採用人工智能和大數據分析時作參考之用。




圖 1：人工智能道德框架概覽

《人工智能道德框架》包括以下主要組成部分：

- **度身訂造的框架**，包含以下子部分：
 - **人工智能道德原則**：界定設計及開發人工智能應用時須遵循的原則。該原則適用於人工智能治理架構中定義的所有角色；
 - **人工智能治理架構**：根據「人工智能道德框架」所訂立的實務，界定採用人工智能過程中的標準架構、角色和責任；
 - **人工智能生命週期**：界定一個人工智能生命週期模型，用於構建人工智能實務指引的布局及人工智能評估中的問題；以及
 - **人工智能實務指引**：為人工智能生命週期的所有階段界定一套實務。這些指導性實務源自「人工智能道德原則」。
- **人工智能評估**：包括「人工智能應用影響評估」範本，該範本界定了目標讀者在人工智能生命週期各階段須回答的問題，以評估人工智能應用或項目的影響，並確保已考慮「人工智能道德原則」。

詳情請參閱《框架》第3章「人工智能道德框架概覽」。

1.3 採納人工智能道德框架的重點行動有哪些？

機構應進行以下重點行動以便採納《框架》：

1. 在整個項目生命週期中全面考慮所有「人工智能道德原則」；
2. 檢視現有的項目管理架構，確保其符合「人工智能治理架構」，並在需要時選擇性成立人工智能道德委員會；以及
3. 遵循「人工智能實務指引」，並就每個人工智能應用完成「人工智能應用影響評估」。

2. 人工智能道德原則

所有人工智能項目均應遵守十二項人工智能道德原則。其中兩項原則，(1) **透明及可解釋** 及 (2) **可靠、穩健及安全** 屬於「執行原則」。這些基本原則是其他原則得以執行的基礎。例如，若未能達致「可靠、穩健及安全」的原則，就無法準確核實其他人工智能道德原則是否一直被遵守。

其他原則歸類為「一般原則」，包括 (1) **公平**、(2) **多元與包容**、(3) **人為監督**、(4) **合法與合規**、(5) **數據私隱**、(6) **安全**、(7) **問責**、(8) **有益的人工智能**、(9) **合作與開放**，以及 (10) **可持續性與公正轉型**。這些原則源自聯合國《世界人權宣言》以及香港有關法例。

各項原則的定義列於表 1。

原則	定義
透明及可解釋	機構應確保能夠以清晰及易於理解的方式，向人解釋明白人工智能應用的決策過程。
可靠、穩健及安全	與其他資訊科技應用一樣，人工智能應用的開發應確保能夠透過使用合適的模型和數據集，在長時間內穩定可靠地運作。在確保運作穩健（即能提供一致的結果並能處理錯誤）的同時，必須按照相關法律和業界框架的要求，抵禦網絡攻擊，維持安全性。
公平	人工智能應用所作出的建議或產生的結果，應以公平方式對待相似群體中的每個人，不應偏袒或歧視，亦不應造成或引致傷害。
多元與包容	應通過了解和尊重所有受影響的持份者的利益，促進人工智能應用的包容性，並兼顧多元化的使用者需求。
人為監督	人工智能應用用於決策或操作過程中所需的人為干預程度，應取決於所涉及的道德問題的嚴重程度。
合法與合規	負責人工智能應用的機構，應貫徹依據法律、規例及相關監管制度行事。

原則	定義
數據私隱	個人應享有以下權利： (a) 獲告知個人資料的收集目的及可能的資料轉移對象，且該個人資料的收集須出於合法目的、以合法及公平的方式進行，並且所收集的資料數量不應超過該目的所需。請參閱《個人資料（私隱）條例》（《私隱條例》）¹的保障資料第1原則「收集目的及方式」。 (b) 獲保證資料使用者已採取所有切實可行的步驟，以確保個人資料是準確無誤，並不保留超過所需的時間。請參閱《私隱條例》的保障資料第2原則「準確性及保留期間」。 (c) 要求個人資料僅用於該資料原本的收集目的及直接與該目的相關。否則須得到個人的明確及自願的同意。請參閱《私隱條例》的保障資料第3原則「個人資料的使用」。 (d) 獲保證資料使用者已採取所有切實可行的步驟，保障其持有的個人資料不會未經授權或意外地被查閱、處理、刪除、喪失或使用。請參閱《私隱條例》的保障資料第4原則「個人資料的保安」。 (e) 獲得相關資訊：(i) 個人資料方面的政策及實務；(ii) 所持有的個人資料的種類；(iii) 個人資料的主要使用目的。請參閱《私隱條例》的保障資料第5原則「資訊須在一般情況下可提供」。
安全	人工智能應用在其整個運作生命週期內，均不應危及人類的身體安全或心理健全。
問責	機構須對其人工智能應用，包括其使用和誤用，所產生的道德影響負責。同時應有明確可識別的問責方，無論是個人或機構。
有益的人工智能	人工智能的發展應促進共同福祉。
合作與開放	應培養人工智能生態環境中多方持份者開放合作的文化。

¹ https://www.pcpd.org.hk/tc_chi/data_privacy_law/ordinance_at_a_Glance/ordinance.html

原則	定義
可持續性與公正轉型	人工智能的發展應確保已制定緩解策略，以應對任何對社會及環境系統的潛在影響。

表 1：人工智能道德原則及定義

詳情請參閱《框架》第3.5.1節「人工智能道德原則」。

3. 人工智能治理

人工智能治理是指管理及控制人工智能項目與應用的實踐方針。「三道防線」是眾多機構廣泛採用的成熟治理概念，圖 2 展示了不同防線及其角色。



圖 2：三道防線模式

該治理架構的組成如下：

- **第一道防線**為項目團隊，負責開發人工智能應用、風險評估、執行風險緩解措施，以及記錄「人工智能評估」工作。
- **第二道防線**由項目督導委員會及項目保證小組組成，確保項目品質，制定人工智能應用的驗收標準，進行獨立檢視，並批准人工智能應用。在予以批准前，須完成「人工智能評估」以確保符合「人工智能道德原則」。
- **第三道防線**涉及資訊科技委員會，如未設立此委員會，則由首席資訊官擔任，並可選擇由人工智能道德委員會提供支援。人工智能道德委員會可由外部顧問組成，就人工智能道德議題提供建議，並加強機構採用人工智能的能力。第三道防線負責審核、建議及監管高風險人工智能應用。

4. 人工智能生命週期

為使機構在開展人工智能項目或開發人工智能應用時有所依循，該《框架》已於「人工智能實務指引」中詳細說明人工智能生命週期各階段的實務規範（詳情請參閱《框架》第4章「人工智能實務指引」）。下列六步流程圖解構人工智能生命週期的概念：




圖 3：人工智能生命週期概覽

人工智能生命週期展示了人工智能項目所涉及各個階段，當中包括：

- 引導機構了解人工智能項目的不同階段及相關要求；以及
- 作為制定人工智能實務的參照，以配合典型的人工智能實際開發階段。

人工智能生命週期不僅適用於訂定《人工智能實務指引》的實務規範，同時與傳統的系統發展生命週期模型互相對應（見圖 4）。




圖 4：「人工智能生命週期」與「系統發展生命週期」模型互相對應

在人工智能應用的典型開發過程中，數據準備工作至關重要，因為優質數據往往是構建良好人工智能模型的基礎。數據收集與預先處理作為項目開發的組成部分，往往需要持續進行，這是因為在整個開發過程中，人工智能模型可通過獲取更優質或更大量的數據來反覆優化訓練效果。傳統軟件生命週期的開發模式，是通過指令集編寫資訊科技應用程式來處理既定情境，其後這些資訊科技應用程式會運用運算能力與其他資源來處理輸入系統的數據。至於人工智能應用的開發模式則截然不同，是通過向系統輸入海量數據進行訓練，在所有數據經處理後，最終生成能解決新問題的人工智能模型或解決方案。

在人工智能生命週期中，開發與部署階段、系統運作與監察之間往往存在持續的反饋循環，以便不斷改進，這有別於傳統的系統發展生命週期。

5. 人工智能實務指引

《框架》第4章「人工智能實務指引」詳細列明多個實務範疇須遵循的實務規範，這些實務範疇屬「人工智能應用影響評估」評核內容的一部分。以下概要說明《人工智能實務指引》所涵蓋的實務範疇：

人工智能生命週期	實務範疇	定義
項目策略	機構的策略、內部政策與實務	機構應能以清晰易懂的方式，向人解釋人工智能應用的決策過程。
	行業標準與規例	須就相關規例及標準進行評估，以確保人工智能及相關流程符合任何適用的法律或標準。
項目規劃	組合管理	進行組合管理，旨在確保機構投放於流程、人員及技術的資訊科技投資符合預期。評估人工智能項目，以確保項目有效滿足業務需求及目標。
	項目監督與交付方式	品質控制不僅監察交付成果的品質，還涉及按「項目管理計劃」所界定的各個環節進行監察。
項目生態環境	人工智能與數據使用的技術路線圖	技術路線圖應使機構能夠規劃及制定策略，以決定採購什麼、何時採購及採購哪種技術，以進行人工智能及大數據分析。
	採購人工智能服務	可為人工智能項目採購現成的產品及數據。在進行此類採購工作時，機構應適當考慮相關道德因素。
項目開發	業務與數據理解	機構應確定使用人工智能的目標，並在決策過程中權衡使用人工智能的效益與風險。
	解決方案設計	機構應評估人工智能應用中的人工智能模型是否切合機構的目標，以及所需的人為介入程度。

人工智能生命週期	實務範疇	定義
	數據提取	機構應確保來自內部或外部不同來源數據的品質、有效性、可靠性及一致性。
	數據預處理	在解決方案開發過程中，須特別謹慎處理含有個人資料的敏感數據，以防出現數據洩漏或違反私隱與安全規定。
	模型構建	模型構建應旨在減少常見的人工智能應用錯誤，例如不準確的模型假設、模型過度擬合及對抗性攻擊。
系統部署	模型整合與影響	核實、驗證及測試過程旨在確保人工智能應用的運作，符合項目初期訂定的要求。這個過程可確保人工智能應用的妥善整合。
	過渡與執行	假定人工智能應用或會出現故障，在部署人工智能應用前，應制定緩解措施，以期盡量減少故障所造成的損害。
	持續監察	提供反饋以監察 / 維護模型的表現及人工智能應用的穩健性。
	評估與檢查	人工智能應用需要具可追溯性、可重複性及可再現性，以確保人工智能應用運作正常，並協助建立公眾及持份者的信任。
系統運作與監察	數據與模型表現監察	由於人工智能模型（作為人工智能應用的一部分）有機會變得不夠準確及不太相關，因此應持續進行監察及檢討。
	運作支援	在部署人工智能應用後，應建立持續的運作支援，以確保人工智能應用的表現保持穩定、可靠及穩健。
	持續審查 / 合規	項目經理（或維護團隊）、項目督導委員會 / 項目保證小組（或維護委員會）及資訊科技委員會 / 首席資訊官（或其代表）

人工智能生命週期	實務範疇	定義
		負責監察人工智能風險，例如不符合相關新 / 修訂法律及規例的情況。

表 2：人工智能道德框架內《人工智能實務指引》所涵蓋的實務範疇

詳情請參閱《框架》第4章「人工智能實務指引」。

6. 人工智能應用影響評估

人工智能應用影響評估應在人工智能生命週期的不同階段進行。該評估為各機構引入系統化思考流程，以便全面審視個別應用的各項考量因素，包括相關效益與風險，同時突顯有額外管治活動的需要，並制定跟進行動以確保實施符合「人工智能道德」的必要措施與管制。

該評估所用的人工智能應用影響評估範本詳見於《框架》附錄C「人工智能應用影響評估範本」，以作參考。

人工智能應用影響評估包含以下組成部分：




圖 5：人工智能應用影響評估的組成部分

應視乎人工智能項目進度及在人工智能應用運作期間，定期（例如每年）或在發生重大變更時進行人工智能應用影響評估。

圖 6 顯示在人工智能生命週期中應檢視人工智能應用影響評估的各個階段。




圖 6：進行人工智能應用影響評估的階段

人工智能應用影響評估可在整個人工智能生命週期內作為「動態」文件使用，但應在人工智能生命週期的4個關鍵階段進行檢視，並保留評估記錄作歷史存檔。下表總結了這些檢視與系統發展生命週期的對應關係，以及負責方和須執行的行動：

生命週期階段	負責方	執行步驟
系統發展生命週期： 項目申請 人工智能生命週期： 項目策略	項目團隊	根據「風險分級問題」的答案，將項目分類為「高風險」或「非高風險」 進行「人工智能應用影響評估」： • 回答問題1-8、9(i)、41-49、57-58
	項目督導委員會 / 項目保證小組	檢視及核准非高風險項目的評估
	資訊科技委員會 / 首席資訊官	檢視及核准高風險項目的評估

生命週期階段	負責方	執行步驟
系統發展生命週期： 系統分析與設計 人工智能生命週期： 項目生態環境 系統開發	項目團隊	進行「人工智能應用影響評估」： • 回答問題9(ii)、10-14、18-19、22-29、30(i)(ii)、31-34、37(i)、52-56 • 根據最新情況檢視及更新問題1-8、9(i)、41-49、57-58的答案 • 如使用第三方技術或數據，須在採購前完成並檢視問題15-17、48
	項目督導委員會 / 項目保證小組	• 檢視及核准評估報告
系統發展生命週期： 實施階段（推出前） 人工智能生命週期： 系統部署	項目團隊	進行「人工智能應用影響評估」： • 回答問題20、21、30(iii)、35、36、37(ii)(iii)、38-40、50、51 • 根據最新情況檢視及更新評估（問題1-14、18-19、22-29、30(i)(ii)、31-34、37(i)、41-49、52-58） • 如使用第三方技術或數據，須檢視問題15-17、48
	項目督導委員會 / 項目保證小組	• 檢視及核准評估報告
系統發展生命週期： 系統維護 （每年或發生重大變更時） 人工智能生命週期： 系統運作與監察	維護團隊	• 根據最新情況檢視及更新「人工智能應用影響評估」 • 呈報任何重大問題
	維護委員會 資訊科技委員會 / 首席資訊官（或其授權代表）	• 處理呈報事項 • 監察高風險項目

表 3：完成及檢視人工智能應用影響評估的執行步驟